

THÔNG TIN CHUNG

- Link YouTube video của báo cáo (tối đa 5 phút):
<https://youtu.be/h1qyvZUXWiM?si=jUmGHD.JObYlxsfQq>
- Link slides (dạng .pdf đặt trên Github của nhóm):
<https://github.com/bilday08/Master-UIT-ResearchMethodology/blob/main/Phan%20H%E1%BB%93ng%20H%E1%BA%A1nh%20-%20CS2205.CH203.DeCuong.FinalRepor.Template.Slide.pdf>
- Link Github:
<https://github.com/bilday08/Master-UIT-ResearchMethodology>
- Họ và Tên:
Phan Hồng Hạnh
- MSHV: 250201057
- Lớp: CS2205.CH203
- Tự đánh giá (điểm tổng kết môn): 9/10
- Số buổi vắng: 1



ĐỀ CƯƠNG NGHIÊN CỨU

TÊN ĐỀ TÀI (IN HOA)

NGHIÊN CỨU HỌC TƯƠNG PHẢN CÓ GIÁM SÁT TRONG PHÂN LOẠI CUNG BẬC CẢM XÚC TIẾNG VIỆT TRÊN MẠNG XÃ HỘI

TÊN ĐỀ TÀI TIẾNG ANH (IN HOA)

SUPERVISED CONTRASTIVE LEARNING FOR VIETNAMESE FINE-GRAINED EMOTION CLASSIFICATION ON SOCIAL MEDIA TEXT

TÓM TẮT (Tối đa 400 từ)

Sự bùng nổ của mạng xã hội tại Việt Nam (Facebook, TikTok, Threads, YouTube) tạo ra khối lượng bình luận khổng lồ phản ánh tâm lý cộng đồng. Việc nhận diện cung bậc cảm xúc chi tiết (fine-grained emotion) thay vì chỉ phân loại tích cực/tiêu cực đóng vai trò then chốt cho chăm sóc khách hàng tự động, quản trị danh tiếng thương hiệu và phân tích dư luận. Tuy nhiên, bài toán đối mặt ba thách thức cốt lõi: văn bản ngắn và nhiễu (từ lóng, teencode, emoji); tính đa nhãn khi một bình luận mang nhiều cảm xúc đan xen; và độ tương đồng cao giữa các cảm xúc gần nghĩa khiến các hàm mất mát truyền thống dễ nhầm lẫn.

Chúng tôi đề xuất một khung kiến trúc nhẹ, kết hợp mô hình ViSoBERT (được huấn luyện trước chuyên biệt cho mạng xã hội tiếng Việt) với một hàm mất mát tương phản có giám sát đóng vai trò điều hòa hình học cho không gian biểu diễn. Hàm mục tiêu kết hợp Binary Cross-Entropy (BCE) với thành phần tương phản: $L_{Joint} = \alpha L_{CE} + (1 - \alpha) L_{SupCon}$. Hai biến thể được so sánh bao gồm: SCL nguyên bản (mọi cặp chia sẻ ≥ 1 nhãn là cặp dương) và JSCL có trọng số Jaccard (gán trọng số mềm theo mức chồng lấn nhãn). Các cặp tương phản được sinh ngẫu nhiên qua cơ chế hai khung nhìn dựa trên dropout, sau đó được chiếu xuống không gian 128 chiều và thực hiện chuẩn hóa L2.

Thực nghiệm trên bộ chuẩn ViGoEmotions (20.664 bình luận, 27 nhãn cảm xúc chi tiết và nhãn trung tính) cho thấy SCL nguyên bản làm giảm Macro F1 do tách lớp quá mạnh, trong khi JSCL giữ ổn định Recall, cải thiện Precision và Subset Accuracy, đồng thời tạo các cụm cảm xúc cô đọng và dễ diễn giải hơn trên t-SNE. Nghiên cứu khẳng định cách định nghĩa cặp dương có ý thức về chồng lấn nhãn là hướng tiếp cận hiệu quả và tiết kiệm tài nguyên cho nhận diện cảm xúc đa nhãn tiếng Việt.

GIỚI THIỆU (Tối đa 1 trang A4)

Trong kỷ nguyên số, mạng xã hội tiếng Việt đã trở thành tấm gương phản chiếu tâm lý người dùng theo thời gian thực. Nhu cầu hiểu cung bậc cảm xúc (ngưỡng mộ, mỉa mai, biết ơn, tuyệt vọng...) ngày càng cấp thiết, vượt xa khả năng của phân loại cảm xúc hai cực truyền thống. Đề tài được lựa chọn vì tính thời sự của dữ liệu mạng xã hội tiếng Việt và vì khoảng trống nghiên cứu: chưa có công trình nào kết hợp đồng thời một mô hình ngôn ngữ chuyên biệt cho mạng xã hội tiếng Việt, bài toán đa nhãn, và tập nhãn cảm xúc chi tiết có độ chồng lấn rất cao.

Văn bản mạng xã hội tiếng Việt vừa ngắn vừa nhiễu (Noise & Brevity); một bình luận thường mang nhiều cảm xúc cùng lúc (Multi-label Overlap); và ranh giới giữa các cảm xúc gần nghĩa rất mờ (High Inter-class Similarity). Các hàm mất mát như CE/BCE chỉ tối ưu ranh giới quyết định mà không định hình cấu trúc không gian biểu diễn, nên dễ trộn lẫn các cảm xúc “song sinh” như buồn và tuyệt vọng.

Mô tả bài toán (Input → Output)

- **Input:** Một đoạn văn bản thô từ mạng xã hội tiếng Việt (có thể chứa từ lóng, teencode, emoji).
- **Output:** Một vector nhãn đa điểm (multi-hot) trên 28 chiều, gồm 27 nhãn cảm xúc chi tiết và 1 nhãn neutral; mỗi bình luận có thể được gán đồng thời nhiều nhãn.

Đối tượng là bài toán phân loại đa nhãn cảm xúc chi tiết cho văn bản mạng xã hội tiếng Việt. Phạm vi được giới hạn ở: backbone ViSoBERT; bộ dữ liệu chuẩn ViGoEmotions; và hai biến thể tương phản SCL và JSCL kết hợp với BCE. Nghiên cứu không bao gồm huấn luyện trước (pre-training) mô hình mới hay so sánh với các LLM tổng quát.

Phương pháp nghiên cứu

Bước	Nội dung	Phương pháp / Công cụ
1	Khảo sát và tổng hợp công trình liên quan	Đọc – tóm tắt – nhận diện mẫu (Pattern Recognition)
2	Chuẩn bị dữ liệu ViGoEmotions	Tiền xử lý, phân tích thống kê (EDA)
3	Xây dựng khung mô hình BCE + SCL/JSCL	ViSoBERT, projection head, PyTorch
4	Huấn luyện & tinh chỉnh	AdamW, Google Colab GPU T4
5	Đánh giá định lượng & định tính	6 độ đo + t-SNE + phân tích lỗi

Nội dung nghiên cứu: Trên cơ sở đó, đề tài tập trung xây dựng khung kiến trúc kết hợp BCE với hàm tương phản, hiện thực hai biến thể SCL/JSCL, huấn luyện trên ViGoEmotions và đánh giá toàn diện nhằm trả lời câu hỏi: cách định nghĩa cặp dương nào phù hợp cho bài toán đa nhãn có chồng lấn cao?

Ứng dụng thực tế: Kết quả có thể được tích hợp vào hệ thống lắng nghe mạng xã hội (social listening), chăm sóc khách hàng tự động và phân tích phản hồi sản phẩm cho thị trường Việt Nam.

MỤC TIÊU *(Viết trong vòng 3 mục tiêu)*

- So sánh hai biến thể tương phản:** Triển khai và đánh giá đối chứng hai cách định nghĩa cặp dương SCL nguyên bản (chồng lấn nhãn > 0) và JSCL có trọng số Jaccard trên bộ ViGoEmotions, định lượng bằng 6 độ đo: Subset Accuracy, Macro Precision, Macro Recall, Macro F1, Weighted F1 và Micro F1.
- Xây dựng khung kiến trúc kết hợp:** Thiết kế và hiện thực một framework phân loại đa nhãn cảm xúc tiếng Việt trên backbone ViSoBERT, kết hợp hàm mất mát phân loại BCE với hàm tương phản có giám sát SCL theo cơ chế đồng huấn luyện $L_{Joint} = \alpha L_{CE} + (1 - \alpha) L_{SupCon}$.
- Phân tích không gian biểu diễn và lỗi:** Trực quan hóa không gian nhúng bằng t-SNE và phân tích ma trận nhầm lẫn cho các cặp cảm xúc dễ lẫn (anger↔annoyance, joy↔amusement...), nhằm lý giải khi nào và vì sao học tương phản phát huy tác dụng hoặc thất bại.

NỘI DUNG VÀ PHƯƠNG PHÁP

1. Nội dung


Học tương phản (Contrastive Learning) tối ưu không gian biểu diễn bằng cách kéo gần các cặp mẫu tương đồng và đẩy xa các cặp khác biệt. Học tương phản có giám sát (SCL, Khosla et al. 2020) tận dụng nhãn để coi mọi mẫu cùng lớp trong một batch là cặp dương, tạo nhiều cặp dương/âm cho mỗi anchor, loss được tính trên biểu diễn đã chuẩn hóa L2 và chia tỉ lệ theo nhiệt độ τ .

Với bài toán đa nhãn, hàm phân loại chính là Binary Cross-Entropy (BCE), coi mỗi trong 28 nhãn là một bài toán nhị phân độc lập. Tuy nhiên BCE bộc lộ ba giới hạn: (1) không trực tiếp học biểu diễn, (2) bỏ qua tương quan giữa các nhãn, và (3) dễ mắc ranh giới cụm bị mờ. Đây chính là động lực để bổ sung thành phần tương phản như một bộ điều hòa hình học. Backbone được chọn là ViSoBERT (Nguyen et al. 2023) - mô hình BERT đơn ngữ (~100 triệu tham số) huấn luyện trước trên văn bản mạng xã hội tiếng Việt, xử lý tốt teencode/emoji và đủ nhẹ để fine-tune trên một GPU T4.

2. Phương pháp

Qua việc tổng hợp các tài liệu liên quan (Related Work), có thể thấy một sự phát triển nối tiếp trong việc ứng dụng học tương phản. Khởi đầu, Khosla et al. (2020) đã đặt nền móng cho SCL trên dữ liệu ảnh đơn nhãn. Tiếp đó, Gunel et al. (2021) chuyển đổi kỹ thuật này sang ứng dụng tinh chỉnh (fine-tune) mô hình ngôn ngữ dưới dạng hàm mục tiêu $L = (1-\lambda) \cdot L_{CE} + \lambda \cdot L_{SCL}$. Kế thừa những nền tảng đó, Lin et al. (2023) đã tổng quát hóa định nghĩa cặp mẫu dương cho văn bản đa nhãn và đề xuất biến thể JSCL dựa trên trọng số Jaccard. Song song với đó, Huang & Usbeck (2024) chứng minh cơ chế đa góc nhìn (two-view) bằng kỹ thuật dropout mang lại hiệu quả cao và tiết kiệm tài nguyên đối với dữ liệu microblog ngắn, nhiều trong khi Kapparad & Mohan (2025) bổ sung thêm các ràng buộc nhằm thắt chặt cụm đặc trưng nội lớp.

Dù vậy, tổng quan tài liệu vẫn cho thấy một khoảng trống nghiên cứu rõ rệt: hiện chưa có công trình nào hợp nhất được cả ba yếu tố bao gồm kiến trúc mã hóa chuyên biệt cho tiếng Việt, mục tiêu học đa nhãn, và khả năng xử lý tập dữ liệu cảm xúc chi tiết có độ chồng lấn cao (đạt mức ~6,9 nhãn trên mỗi mẫu).



Hình 1. Sơ đồ pipeline tổng quát của Kiến trúc đề xuất cho phân loại đa nhãn cảm xúc bình luận

Hình ảnh minh họa toàn diện **Kiến trúc đề xuất cho phân loại đa nhãn cảm xúc bình luận**, mô tả chi tiết luồng xử lý từ văn bản thô qua bộ mã hóa ViSoBERT để trích xuất vector [CLS] (768 chiều). Biểu diễn này sau đó được tách thành hai luồng song song: một nhánh phân loại tạo ra 28 logits để tính mất mát phân loại L_{BCE} , và một nhánh tương phản đi qua Projection Head và chuẩn hóa L2 để tính mất mát tương phản L_{Con} . Điểm nhấn của kiến trúc là cơ chế sinh cặp tương phản (two-view), tận dụng kỹ thuật dropout ngẫu nhiên khi đưa bình luận qua bộ mã hóa hai lần. Quá trình này giúp tạo ra hai khung nhìn (view) khác biệt nhẹ về mặt hình học nhưng hoàn toàn đồng nhất về ngữ nghĩa mà không cần phải thực hiện tăng cường dữ liệu thủ công.

Kiến trúc tối ưu hóa mô hình thông qua hàm mất mát tổng hợp kết hợp linh hoạt giữa mất mát phân loại (BCE có làm mượt nhãn) và mất mát tương phản (áp dụng SCL nghiêm ngặt hoặc JSCL với trọng số mềm Jaccard kéo gần các cặp theo mức độ chồng lấn nhãn). Hình ảnh cũng bảng hóa rõ ràng cấu hình huấn luyện, cho thấy hệ thống được fine-tune end-to-end trên Google Colab (GPU T4) bằng thuật toán tối ưu AdamW, learning rate 2×10^{-5} , kích thước batch 16 trong 5 epochs. Thiết lập chuẩn hóa này tạo tiền đề vững chắc để đánh giá và so sánh độ hiệu quả giữa ba phiên bản mô hình: BCE baseline, BCE kết hợp

SCL và BCE kết hợp JSCL trên cùng một điều kiện khởi tạo (seed).

KẾT QUẢ MONG ĐỢI

1. Bảng so sánh định lượng (kỳ vọng, dựa trên thực nghiệm sơ bộ).

Trên tập Validation:

Mô hình	Subset Acc	Macro P	Macro R	Macro F1	Weighted F1	Micro F1
ViSoBERT (BCE baseline)	0.2633	0.6595	0.4521	0.5271	0.5523	0.5653
ViSoBERT + SCL	0.2546	0.6835	0.4210	0.5056	0.5382	0.5571
ViSoBERT + JSCL	0.2643	0.6788	0.4574	0.5376	0.5618	0.5737

Trên tập Test:

Mô hình	Subset Acc	Macro P	Macro R	Macro F1	Weighted F1	Micro F1
ViSoBERT (BCE baseline)	0.2535	0.6634	0.4629	0.5382	0.5647	0.5762
ViSoBERT + SCL	0.2477	0.6650	0.4308	0.5116	0.5450	0.5624
ViSoBERT + JSCL	0.2550	0.6712	0.4551	0.5345	0.5610	0.5731

Nhận xét kỳ vọng: trên validation, JSCL cải thiện Macro Precision (+1,93 điểm), Subset Accuracy (+0,10 điểm) và Macro F1 (+1,05 điểm) so với baseline, đồng thời giữ Recall gần như không đổi, SCL strict tuy tăng Precision nhưng đánh đổi Recall nên giảm F1. JSCL là mô hình duy nhất tăng Precision mà không mất Recall.

2. Phân tích không gian nhúng (t-SNE). Baseline cho một “blob” lớn các cảm xúc trộn lẫn. SCL tách cụm rõ nhưng quá xa, đẩy các cảm xúc đáng lẽ gần nhau (amusement/excitement) ra xa; JSCL ở chế độ trung gian và cụm độc lập (gratitude) thì cô đọng, cụm liên quan thì vẫn gần nhau, đúng kỳ vọng của trọng số Jaccard.
3. Phân tích lỗi. Lỗi tập trung vào các cặp “song sinh” cùng họ cảm xúc: anger↔annoyance (59 trường hợp), disgust↔annoyance (58), joy↔amusement (31), sadness↔disappointment (25). Một nhóm lỗi khác đến từ mĩa mai và “chửi đùa” kèm emoji, cho thấy tối ưu hàm mất mát là chưa đủ.
4. **Hướng ứng dụng:** Hệ thống lắng nghe mạng xã hội, phân tích phản hồi khách hàng và giám sát danh tiếng thương hiệu cho dữ liệu tiếng Việt.
5. **Hướng phát triển:** Tích hợp ràng buộc thắt chặt cụm (CES-CL); mô hình hóa mĩa mai và emoji bằng tín hiệu phụ trợ; tăng batch size/epoch và lặp nhiều seed để củng cố tính thống kê của kết quả.

TÀI LIỆU THAM KHẢO

- [1]. P. Khosla, P. Teterwak, C. Wang, A. Sarna, Y. Tian, P. Isola, A. Maschinot, C. Liu, and D. Krishnan, "Supervised Contrastive Learning," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, pp. 18661–18673.
- [2]. B. Gunel, J. Du, A. Conneau, and V. Stoyanov, "Supervised Contrastive Learning for Pre-trained Language Model Fine-tuning," in *Proc. International Conference on Learning Representations (ICLR)*, 2021.
- [3]. N. K. Nguyen, D. V. Thin, et al., "ViSoBERT: A Pre-trained Language Model for Vietnamese Social Media Text Processing," in *Proc. 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2023, pp. 5191–5207.
- [4]. T. Wang, J. Lin, et al., "Revisiting Supervised Contrastive Learning for Microblog Classification," in *Proc. 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2024.
- [5]. D. Demszky, D. Movshovitz-Attias, J. Ko, A. Cowen, G. Nemade, and S. Ravi, "GoEmotions: A Dataset of Fine-Grained Emotions," in *Proc. 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2020, pp. 4040–4054.
- [6]. J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," in *Proc. NAACL-HLT*, 2019, pp. 4171–4186.
- [7]. UIT-NLP, "ViGoEmotions: A Vietnamese Fine-Grained Emotion Dataset for Social Media and E-commerce Text," HuggingFace Datasets, uitnlp/vigoemotions. [Online]. Available: <https://huggingface.co/datasets/uitnlp/vigoemotions>
- [8]. L. van der Maaten and G. Hinton, "Visualizing Data using t-SNE," *Journal of Machine Learning Research*, vol. 9, pp. 2579–2605, 2008.